

資料探勘教學小計畫


■ 授課講師 陳少君

■ 教材編寫 陳少君

緯育 *TibaMe*

即學・即戰・即就業

<https://www.tibame.com/>



學習目標：

- 了解教學方式與進度

Module 0.

教學目的方 式與進度

目的方式與進度

為何而學

資料探勘為資料科學之中心課程，在機器學習盛行之前，Data Mining是探索資料(Data)的洞見(Insight)和知識(Knowledge)最重要的課程與工具


學會之後能幹嘛：知識的煉油工業，從資料提煉(PANDAS)知識，分析(NUMPY/SKLEARN)之後展現在報表/圖表(MATPLOTLIB)上

承先啟後

先備知識：數學概念：基本幾何，線性代數，或然率，一點點微積分。Python/R 程式語言

進階：機器學習，深度學習

資料科學知識示意地圖




第一天(xx月xx日)：以 Python 實作 為主
輸入 (PANDAS)
運算 (NUMPY)
圖表 (MATPLOTLIB/SEABORN)

第二天(yy月yy日)：介紹與實作
探索性資料分析 或稱 EDA(Exploratory Data Analysis)
關聯規則分析 Association Rules Analysis
Sci-Kit Learn (Sklearn) 演算法簡介
Bonus: A/B Test



預習：PANDAS，NUMPY，MATPLOTLIB

作業：EDA，ASSOCIATION RULES readings



CSV: Comma Separate Values

XML: eXtended Markup Language

JSON: Javascript Object Notation

CSV

```
name,age
James Kirk,40
Jean-Luc Picard, 45
WesleyCrusher,27
```


XML


```
<empinfo>
  <employees>
    <employee>
      <name>James Kirk</name>
      <age>40</age>
    </employee>
    <employee>
      <name>Jean-Luc Picard</name>
      <age>45</age>
    </employee>
    <employee>
      <name>Wesley Crusher</name>
      <age>27</age>
    </employee>
  </employees>
</empinfo>
```

JSON

```
{ "empinfo" :
  {
    "employees" : [
      {
        "name" : "James Kirk",
        "age" : 40,
      },
      {
        "name" : "Jean-Luc Picard",
        "age" : 45,
      },
      {
        "name" : "Wesley Crusher",
        "age" : 27,
      }
    ]
  }
}
```


盒鬚圖(Boxplot)




$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \times \begin{bmatrix} 10 & 11 \\ 20 & 21 \\ 30 & 31 \end{bmatrix}$$
$$= \begin{bmatrix} 1 \times 10 + 2 \times 20 + 3 \times 30 & 1 \times 11 + 2 \times 21 + 3 \times 31 \\ 4 \times 10 + 5 \times 20 + 6 \times 30 & 4 \times 11 + 5 \times 21 + 6 \times 31 \end{bmatrix}$$
$$= \begin{bmatrix} 10 + 40 + 90 & 11 + 42 + 93 \\ 40 + 100 + 180 & 44 + 105 + 186 \end{bmatrix} = \begin{bmatrix} 140 & 146 \\ 320 & 335 \end{bmatrix}$$

用途：求線性迴歸(Linear Regression)係數(截距，斜率)，特徵值降維(PCA)，加速矩陣運算等

轉置矩陣

Transposing a 2x3 matrix to create a 3x2 matrix

$$\begin{bmatrix} 6 & 4 & 24 \\ 1 & -9 & 8 \end{bmatrix}^T = \begin{bmatrix} 6 & 1 \\ 4 & -9 \\ 24 & 8 \end{bmatrix}$$

Java67.com

反矩陣

THE INVERSE MATRIX

Inverse Matrix

the inverse matrix that meets the criteria of

$$A \times A^{-1} = I$$

$$\begin{bmatrix} 3 & 4 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & -2 \\ -\frac{1}{2} & \frac{3}{2} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Study.com

```
import numpy as np
x = np.arange(10)
print(x)
[0,1,2,3,4,5,6,7,8,9]
print (x[2:5])
[2,3,4]
print (x[:-7])
[0,1,2]
print(x[1:7:2])
[1,3,5]

x = np.arange(10,1,-1)
print (x)
[10,9,8,7,6,5,4,3,2]
print(x[np.array([3,3,-3,8])])
```

```
[7,7,4,2]
print(x[np.array([[1,1],[2,3]])])
[[9,9],
 [8,7]]

y = np.arange(35).reshape(5,7)
print(y)
[[0,1,2,3,4,5,6],
 [7,8,9,10,11,12,13],
 [14,15,16,17,18,19,20],
 [21,22,23,24,25,26,27],
 [28,29,30,31,32,33,34]]
print(y[1,5,2::3])
[[7,10,13],
 [21,24,27]]
```



Covariance Formula

For Population

$$\text{Cov}(x,y) = \frac{\sum (x_i - \bar{x}) * (y_i - \bar{y})}{N}$$





For Sample

$$\text{Cov}(x,y) = \frac{\sum (x_i - \bar{x}) * (y_i - \bar{y})}{(N - 1)}$$



Correlation Coefficient Formula

$$= \frac{\sum [(X - X_m) * (Y - Y_m)]}{\sqrt{[\sum (X - X_m)^2 * \sum (Y - Y_m)^2]}}$$



Educba.com

2 小時

EDA:
房地產價格分析



2 小時

ASSOCIATION
RULES
購物籃分析



2 小時


迴歸(Regression)
分類(Classification)
分群(Clustering)


作業：投影片連結
及線上作業

Filter(過濾法)：按照發散性或**相關性**對各個特徵進行評分，設定閾值或者待選擇特徵的個數進行篩選 (SelectKBest)


Wrapper(包裝法)：根據目標函數（往往是預測效果評分），每次選擇若干特徵，或者排除若干特徵 (RFE)

Embedded(嵌入法)：先使用某些機器學習的模型進行訓練，得到各個特徵的權值係數，根據係數從大到小選擇特徵（類似於Filter，只不過係數是通過訓練得來的）(SelectFromModel)






FP-growth 的算法，假設 min. support threshold = 3




FP-growth 演算法資料結構解答



[解答：本例FP-growth 演算法一步步詳解-](#)

線性回歸是以一組獨立特徵去預測一個連續型的依變數，用來解決迴歸（預測）問題。目的就是要找到一條線性方程式，能夠最符合，我們的數據分布，最能夠代表我們的變數間的關係。



$$y_i = b_0 + b_1 x + e$$

Estimated (or predicted) y value

Estimate of the regression intercept


Estimate of the regression slope

Independent variable

Error term

From: Datascience.foundation

要比較線性迴歸模型之間的好壞，需要客觀的判準。我們可定義一目標函數，往往是計算誤差的大小或是損失，據以判斷，比方：



$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}|$$

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2$$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2}$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y})^2}{\sum (y_i - \bar{y})^2}$$

Where,


$\hat{y}$ – predicted value of y
 $\bar{y}$ – mean value of y

演算法：混淆矩陣(Confusion Matrix)


混淆矩陣 (confusion matrix)，又稱為可能性表格或是錯誤矩陣。

用來評價算法或者分類器的結果分析表。

每一列代表預測值
每一行代表實際值



Sigmoid是一個有界，可微分的實函數，每一點之導數皆為正，且只有一個拐點。因輸出值介於0與1之間，適合做機率的邏輯分類(0,1)。



pic from: sohu.com


Sigmoid 模型
$$h\theta(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

損失函數：
$$Cost(h_\theta(x), y) = \begin{cases} -\log(h_\theta(x)) & \text{if } y = 1 \\ -\log(1 - h_\theta(x)) & \text{if } y = 0 \end{cases}$$


也可表達為
$$J(\theta) = -\frac{1}{m} \sum \left[y^{(i)} \log(h\theta(x(i))) + (1 - y^{(i)}) \log(1 - h\theta(x(i))) \right]$$

機器學習的參數是： β_0 , β_1

Towardsdatascience.com




支持向量指的是兩個類別(比方藍和綠)資料中最靠近彼此(或者最突出)的樣本。



Javapoint.com


SVM 核函式可以映射至高維的方式解決非線性的問題

非線性問題



Pic from: stackverflow.com

映射至高維



Pic from: medium.com

Bayes' Theorem

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

教室裡有24人，8人熱愛運動，14人是男生，男生且熱愛運動有5人，假設某A喜歡運動，此人為男生的機率是多少？



Bayes' Theorem

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

$$P(\text{熱愛運動}|\text{男}) = \frac{P(\text{男} \cap \text{熱愛運動})}{P(\text{男})} = \frac{5/24}{14/24} = 5/14$$

$$P(\text{男}|\text{熱愛運動}) = \frac{P(\text{熱愛運動}|\text{男}) P(\text{男})}{P(\text{熱愛運動})} = \frac{5/14 * 14/24}{8/24} = (5/24)/(8/24) = 5/8$$


Classification vs Clustering



medium.com

情境：希望能透過網頁設計的改變，提高 **conversion rate**，進而增加收入提升利潤。

右圖是 **conversion rate** 的樣本統計分佈。雖是二項式分佈，但因中央極限定理(CLT)，大樣本可用常態分佈計算。



目的：以統計分析方式檢定改變(新網頁設計，新藥，新教學方法)是否有效

步驟：

1. 分為實驗組(treatment group)與對照組(control group)
2. 決定樣本數大小，一般1:1
3. 隨機取樣(AB樣本需互斥)
4. 定位為雙樣本比例之平均值是否相等之假設檢定。虛無假設：相等。
5. $\text{Alpha} = 0.05$ (type 1 error = 0.05)， $\text{Power} = 0.8$ (type 2 error = $1 - 0.8 = 0.2$)
6. 求取z-score(z-分數)與p-value (如顯著需要 $|z\text{-score}| > 1.96$ ， $p < 0.05$)
7. 求取95%信賴區間 (confidence interval)
8. 判斷改變是否顯著

```
import statsmodels.stats.api as sms
effect_size = sms.proportion_effectsize(0.13, 0.15)
required_n = sms.NormalIndPower().solve_power(
    effect_size,
    power=0.8,
    alpha=0.05,
    ratio=1
)                                     # Calculating sample size needed
required_n = ceil(required_n)
```



```
z_stat, pval = proportions_ztest(successes, nobs=nobs)
(lower_con, lower_treat), (upper_con, upper_treat)
= proportion_confint(successes, nobs=nobs, alpha=0.05)
```

```
z statistic: -0.34
p-value: 0.732 #不顯著
ci 95% for control group: [0.114, 0.133] (0.13在裏頭，
但達不到0.15)
ci 95% for treatment group: [0.116, 0.135]
```

題目：教室裡有30個學生，男生20人，喜歡打電動的有15人，女生之中喜歡打電動的有 $3/5$ 。如果此人喜歡打電動，她是女生的機率是多少？

$$P(\text{女}) = 1 - P(\text{男}) = 1 - 20/30 = 10/30 = 1/3$$

$$P(\text{熱愛電動}|\text{女}) = 3/5$$

$$P(\text{熱愛電動}) = 15/30 = 1/2$$

$$P(\text{熱愛電動}|\text{女}) = 3/5$$

$$P(\text{女}|\text{熱愛電動}) = \frac{P(\text{熱愛電動}|\text{女}) P(\text{女})}{P(\text{熱愛電動})} = \frac{3/5 * 1/3}{1/2} = (1/5)/(1/2) = 2/5$$